

# **Nástroj pro monitorování chování uživatelů webových aplikací**

**A tool for monitoring web  
application user behaviour**

Souhlasím se zveřejněním této bakalářské práce dle požadavků čl. 26, odst. 9 *Studijního a zkušebního řádu pro studium v bakalářských programech VŠB-TU Ostrava*.

V Ostravě 20. dubna 2011

.....

Prohlašuji, že jsem tuto bakalářskou práci vypracovala samostatně. Uvedla jsem všechny literární prameny a publikace, ze kterých jsem čerpala.

V Ostravě 20. dubna 2011

.....

Rád bych na tomto místě poděkoval svým rodičům za podporu během celého studia, panu Ing. Michalovi Radeckému, za vedení během vypracování diplomové práce a své přítelkyni Míše.

## **Abstrakt**

Cílem práce je vytvoření nástroje, jakožto podpory pro aplikaci a navržení metody získávání informací o chování uživatele webové aplikace. Nebude se jednat o klasický přístup založený na sběru statistických dat anonymních návštěvníků, ale o využití znalosti o konkrétním uživateli, jeho chování, využívání funkcí a služeb webové aplikace.

Výsledkem praktické části je webová aplikace ...

**Klíčová slova:** webová analytika, chování uživatelů, webová aplikace, diplomová práce

## **Abstract**

The goal of this thesis is to create a tool to aid web application development and to create a method for gaining knowledge of the web application users' behaviour. It is not the case of usual anonymized data gathering, but make use of the knowledge of concrete user, his behaviour and his usage of web app's functions and services.

**Keywords:** web analytics, user behaviour, web application, master thesis

## **Seznam použitých zkratek a symbolů**

- |      |  |
|------|--|
| GUI  | – Grafické uživatelské rozhraní (Graphical User Interface)         |
| HTML | – Jazyk pro vytváření webových stránek (HyperText Markup Language) |

## Obsah

<b>1</b>	<b>Úvod (3 stránky)</b>	<b>4</b>
1.1	Historie webové analytiky . . . . .	4
<b>2</b>	<b>Sběr a interpretace dat (15 stránek)</b>	<b>7</b>
2.1	Analýza dat z logovacích souborů . . . . .	7
2.2	Informace získané pomocí HTTP protokolu . . . . .	8
2.3	Události v prohlížeči . . . . .	9
2.4	Informace získané pomocí JavaScriptu . . . . .	9
2.5	Derivované informace . . . . .	9
2.6	Interpretace a Vizualizace dat . . . . .	9
2.7	Clickstream analýza . . . . .	10
2.8	Měření konverze . . . . .	10
<b>3</b>	<b>Návrh (15 stránek s diagramy)</b>	<b>11</b>
3.1	Hypotéza . . . . .	11
3.2	Sběr dat . . . . .	11
3.3	Interpretace dat . . . . .	11
3.4	Etická stránka sběru dat . . . . .	11
<b>4</b>	<b>Implementace (20 stránek i s grafy)</b>	<b>12</b>
4.1	Popis technického řešení (10 Stran) . . . . .	12
4.2	Aplikace v reálném provozu (10 stran i s grafy) . . . . .	12
4.3	Navrhnuté změny na základě získaných dat (2 stránky) . . . . .	12
<b>5</b>	<b>Zhodnocení (2 stránky)</b>	<b>13</b>
<b>6</b>	<b>Závěr (1 stránka)</b>	<b>14</b>
<b>7</b>	<b>Reference</b>	<b>15</b>

## Seznam obrázků

1	Analog - denní návštěvnost . . . . .	5
---	--------------------------------------	---

## Seznam výpisů zdrojového kódu

1	Ukázka záznamu z logovacího souboru ve formátu RFC931 . . . . .	4
2	Formát logovacího souboru dle RFC931 . . . . .	7
3	Ukázka HTTP hlavičky . . . . .	8



## 1 Úvod (3 stránky)

Tato diplomová práce se zabývá webovou analytikou. Úvodem popisuje jaký problém webová analytika řeší, nastiňuje historii měření na webu a současné nejčastější využití nástrojů pro webovou analytiku.

V první kapitole popisuje nejčastěji používané techniky měření a vizualizace dat, vysvětluje motivace za jednotlivými technikami a případy užití.

Druhá kapitola se zabývá návrhem nové techniky měření, která se zajímá o to, které funkce webové aplikace uživatelé používají. Popisuje jakým způsobem budou data získána a celý systém jako celek.

Třetí kapitola "Implementace" je zaměřena na použité technologie a konkrétní procesy sběru a analýzy dat.

Čtvrtá kapitola následuje aplikací vzniklého nástroje na existující webovou aplikaci. Cílem je ověřit, že vyvinutý nástroj přináší očekávané výsledky.

V poslední kapitole dochází ke zhodnocení zda metoda měření i nástroj plní očekávání, jaký je jejich přínos pro jejich uživatele v praxi a porovnání s podobnými nástroji.

### 1.1 Historie webové analytiky

#### 1990 - Zrození WWW stránek

Na začátku devadesátých let došlo ke zrození WWW stránek[reference]. Uživatelé tehdy prohlíželi statické stránky a pokaždé, když si nějakou prohlédli, vznikl záznam v logovacím souboru, takzvaný "hit". Počet hitů se stal ukazatelem úspěšnosti webových stránek.

#### 1994 - Mosaic: První masově úspěšný grafický prohlížeč

V roce devadesát čtyři vznikl grafický webový prohlížeč s názvem Mosaic[reference]. Díky jeho snadné instalaci a srozumitelnému uživatelskému rozhraní se web otevřel široké veřejnosti. Tento prohlížeč byl později přejmenován na Netscape a v roce 1995 ho používalo 80% uživatelů internetu.

#### 1995 - Analog: Analýza logovacích souborů

V roce devadesát pět vznikl Analog - nástroj pro analýzu logovacích souborů. Jeho autor Stephen Turner ho poskytoval zdarma jako freeware pro několik platform. Jednalo se o první sofistikovaný nástroj pro analýzu a zobrazení návštěvnosti webových stránek.

---

```
10.20.30.40 -- [26/Apr/2000:00:23:48 -0400] "GET_/index.html_HTTP/1.0" 200 6248 "http://www.jafsoft.com/asctortf/" "Mozilla/4.05_(Macintosh;_I;_PPC)"
10.20.30.40 -- [26/Apr/2000:00:23:48 -0400] "GET_/background.gif_HTTP/1.0" 200 4005 "http://www.example.org/" "Mozilla/4.05_(Macintosh;_I;_PPC)"
```

---


Výpis 1: Ukázka záznamu z logovacího souboru ve formátu RFC931

Logovací soubor obsahuje jeden řádek pro každou návštěvu stránky, nebo souboru na serveru. Nástroj pro analýzu logovacích souborů z toho pak dokáže zjistit kolik měl

server návštěv každý den, z kolika unikátních IP adres, které stránky jsou nejnavštěvovanější a kolik bylo přenesených dat.

The data collection became unusable with the advent of search engines and their robots, proxies servers to surf anonymously, allocation of dynamic IP addresses by ISPs and cached content techniques. All these developments have rendered the use of log files inappropriate to analyze user behavior. The data contained in log files were indeed biased and unique visitor identification almost impossible.

Each unit (■) represents 30 requests for pages or part thereof.



Obrázek 1: Analog - denní návštěvnost

## 1996 - Měření pomocí kódu na stránce

V roce 1996 byl v obou nejpoužívanějších prohlížečích<sup>1</sup> k dispozici JavaScript.

Tvůrce webových stránek na každou stránku umístil kód, který mu vygeneroval poskytovatel měřícího nástroje.

Tento postup se zásadně liší od analýzy logových souborů. Místo statické analýzy zaznamenaných dat na straně serveru tento přístup data dynamicky sbírá na straně klienta.

Tento průlom umožnil použití třetích stran pro sběr i vyhodnocení dat a tak dal vzniknout prvním online nástrojům pro webovou analytiku. V různých obměnách se tato technika používá dodnes.

## 2005 - Moderní webová analytika pro každého

V roce 2005 koupila společnost Google analytický systém Urchin on Demand a ještě v témž roce ho poskytla zdarma široké veřejnosti jako webovou aplikaci pod názvem Google Analytics.

Pro obrovský zájem byl tento produkt zpřístupněn pouze omezenému počtu uživatelů. Od října roku 2006 byly znovu otevřeny volné registrace a dodnes se jedná o nejpoužívanější systém pro webovou analytiku.

<sup>1</sup>V roce 1996 měl Netscape Navigator zhruba 80% podíl a Internet Explorer 14%

## **2011 - Sociální média a zařízení**

S nástupem sociálních médií a chytrých mobilních zařízení dochází k nárůstu času, který uživatelé tráví na internetu. Poměrně k tomuto nárůstu se zvyšují investice do internetových stránek a webových aplikací.

Na jedné straně je snaha dostat nové uživatele na svou stránku, to se dociluje například pomocí optimalizace pro vyhledávače, reklamních bannerů, nebo PPC reklamy<sup>2</sup>. V tomto případě slouží webová analytika k měření efektivity jednotlivých kampaní a k jejich následné optimalizaci.

Na druhé je snaha pracovat s uživateli, které už webová stránka, nebo aplikace má. Zde je snaha identifikovat problémy a optimalizovat uživatelskou zkušenost. V obou případech je to webová analytika, která nám umožňuje získat přehled, optimalizovat a vyhodnotit návratnost investic.

---

<sup>2</sup>PPC - Pay per click, platba se za proklik (cena prokliku je určena pomocí aukce).

## 2 Sběr a interpretace dat (15 stránek)

Podstatou webové analytiky je sběr a interpretace dat. Jak již bylo řečeno, sběr dat se za dobu existence webu vyvinul z pasivní formy analýzy logových souborů na serveru do dnešní - aktivního sběru dat na straně uživatele třetí stranou.

Tato kapitola popisuje používané způsoby sběru dat s důrazem na to, jaké informace z nich získáváme, jaké další informace z nich můžeme vyčíst a jaké způsoby vizualizace se běžně vyskytují.

### 2.1 Analýza dat z logovacích souborů

Webové servery zaznamenávají zobrazení stránek do takzvaných logovacích souborů. Jedná se o soubory, ve kterých každý řádek představuje záznam o jednom zobrazení stránky, nebo například obrázku.

Když na začátku devadesátých let vznikl web, provozovatelé serverů si uvědomili, že tyto soubory umožňují získat informace o popularitě jejich stránek a tak začali měřit počet zobrazení, takzvaných "hitů". V té době se vyskytovaly většinou pouze dlouhé stránky bez obrázků nebo odkazů, takže počet zobrazení postačoval potřebám provozovatelů.

---

127.0.0.1 – frank [10/Oct/2000:13:55:36 –0700] "GET /apache\_pb.gif HTTP/1.0" 200 2326

---

Výpis 2: Formát logovacího souboru dle RFC931

127.0.0.1	IP adresa návštěvníka. Počet unikátních IP adres byl původně používán jako hrubý odhad počtu uživatelů.
–	pomlčka
frank	Uživatelské jméno. Tento údaj je přítomen v případě se stránka používá HTTP autentifikaci. To platí pro stránky s omezením přístupu pro uzavřenou skupinu lidí a tudíž u náhodného návštěvníka stránky tento údaj nenajdeme. V takovém případě se místo uživatelského jména zaznamená pomlčka.
10/Oct/2000	Datum návštěvy.
13:55:36	Čas návštěvy, vztahuje se k časové zóně na serveru.
–0700	Časová zóna.
GET /apache_pb.gif	Požadavek a verze HTTP protokolu

HTTP/1.0	Požadavek HTTP protokolu. GET je základním požadavkem, který signalizuje, že uživatel požaduje nějaký obsah. Další používaný požadavek je například POST, který se používá pro odeslání formuláře na server.
200	Kód odpovědi. Kód 200 znamená vše v pořádku. Obvyklé a pro webovou analytiku také zajímavé jsou 404 - stránka nenalezena, 500 - problém na serveru, nebo 303 - přesměrování stránky.
2326	Délka odpovědi v bajtech. Sledování této veličiny spolu s počtem návštěv umožňuje identifikovat, který obsah nejvíce zatěžuje internetové připojení daného serveru.

Jak web rostl, tak i jeho složitost a z jednoduchých stránek bez obrázků se staly různě provázené stránky s odkazy a obrázky. S vzrůstající složitostí internetových stránek se i nástroje pro analýzu logovacích souborů stávaly sofistikovanější a začaly na sebe nabírat další možnosti.

Pole zaznamenávaných dat sbíraných v logovacích souborech byl rozšířen o další informace HTTP protokolu, kterými se zabývá další část kapitoly. Samotný formát je z hlediska analytiky vedlejší a není již nutno ho rozebírat.

## 2.2 Informace získané pomocí HTTP protokolu

Prohlížení webových stránek na internetu je zajištěno pomocí HTTP protokolu. HTTP je zkratka pro Hyper Text Transfer Protokol, neboli protokol pro výměnu hypertextů (hypertextových stránek). Je to způsob, jak webový prohlížeč komunikuje s webovým serverem.

Pomocí HTTP protokolu poskytuje prohlížeč informace o uživateli tak, aby webový server mohl co nejlépe vyhovět požadavku.

---

```
GET /dumprequest HTTP/1.1
Host: djce.org.uk
Connection: keep-alive
Accept: application/xml,application/xhtml+xml,text/html;q=0.9,text/plain;q=0.8,image/png,*/*;q=0.5
User-Agent: Mozilla/5.0 (X11; U; Linux i686; en-US) AppleWebKit/534.16 (KHTML, like Gecko) Chrome/10.0.634.0 Safari/534.16
Accept-Encoding: gzip,deflate,sdch
Accept-Language: cs-CZ,cs;q=0.8
Accept-Charset: windows-1250,utf-8;q=0.7,*;q=0.3
```

---

Výpis 3: Ukázka HTTP požadavku

**Prohlížeč a verze**

**Geolokace**

**referrer**

**stránka**

**query string**

## **2.3 Události v prohlížeči**

**Pohyb myši**

**Klikání**

**Používání kláves**

**Odchod ze stránky**

**Skrolování stránky**

## **2.4 Informace získané pomocí JavaScriptu**

**Rozlišení obrazovky**

**Velikost viewportu**

(zobrazení stránek, jako analýza logů)

## **2.5 Derivované informace**

**Doba strávená na stránce**

**Loajalita = opakování návštěv**

**Častost návštěv**

**Počet návštěv**

**Počet unikátních uživatelů**

## **2.6 Interpretace a Vizualizace dat**

**Heatmapy**

**Heatmapy**

**Světová mapa**

**Segmentace**

Aplikace v praxi - optimalizace kampaní - A/B / split testing

## **2.7 Clickstream analýza**

## **2.8 Měření konverze**

### 3 Návrh (15 stránek s diagramy)

O čem je tahle kapitola?

#### 3.1 Hypotéza

Popis problému.

Demonstrovat na příkladu.

Popis řešení.

Co se bude měřit a proč.

Co nástroj dělá a proč.

Co nástroj nedělá a proč ne.

Pro koho je nástroj určen.

Existuje nějaký podobný nástroj?

Proč takový nástroj ještě neexistuje? (implementují si in house řešení tohoto problému)

#### 3.2 Sběr dat

Jaké data nás zajímají a proč

Jaké data nás nezajímají a proč

Jaké jsou omezení sběru dat.

#### 3.3 Interpretace dat

Jaké možnosti interpretace dat jsou?

Jaké možnosti se hodí?

Jaké možnosti interpretace dat jsme zvolili a proč?

Jaké jsou možnosti segmentace. Jaké jsou možnosti do budoucna.

Možnosti aproximace?

#### 3.4 Etická stránka sběru dat

Problém etiky sběru dat. Právní problémy. Anonymní vs. neanonymní data. Webaplikace vs. webová stránka. Zákazník vs. náhodný návštěvník. Analogie z fyzického byznysu.



## **4 Implementace (20 stránek i s grafy)**

O čem je tato kapitola?

### **4.1 Popis technického řešení (10 Stran)**

- 1) diagram celého systému
- 2) detail sběru dat
- 3) detail interpretace dat
- 4) zobrazení dat

vizualizační technologie, appengine proč jsem vybral tyto technologie detaily funkce měřicího skriptu (AES) detaily sběru dat detaily analýzy dat

### **4.2 Aplikace v reálném provozu (10 stran i s grafy)**

obecně kolik dat tam lítalo denně, kolik uživatelů analýza dat (na co jsem se zaměřil)  
zajímavé grafy, co z nich vyplývá závěry (navrhnout změny)

### **4.3 Navrhnuté změny na základě získaných dat (2 stránky)**

## 5 Zhodnocení (2 stránky)

co splnilo očekávání co nesplnilo / předčilo očekávání přínos pro uživatele v praxi porovnání s podobnými nástroji

## 6 Závěr (1 stránka)

Byla to bomba :)

Michal Hantl

## 7 Reference

- [1] Pecinovský, Rudolf, *Jak efektivně učit OOP. Tvorba softwaru 2005 – sborník přednášek*, ISBN 80-86840-14-X.
- [2] Pecinovský, Rudolf, *Současné trendy v metodice výuky programování*, dostupné z url <http://gynome.nmm.cz/konference/files/2006/sbornik/pecinovsky.pdf>.
- [3] Plamínek, Jiří, *Tajemství motivace – Jak zařídit, aby pro vás lidé rádi pracovali*, ISBN 80-247-1991-6.
- [4] Gašparovičová Ľuba, Hvorecký, Josef, *Kamarádi Robota Karla*, ISBN 80-06-00421-8.